Informe Técnico

Integrantes del grupo

Carnet	Nombre	Rol
202203069	Bruce Carbonell Castillo Cifuentes	coordinador
202209714	Angel Enrique Alvarado Ruiz	el que hace lo que dice el coordinador

1. Fuentes de datos y mapeo hacia el modelo

Fuente	Archivo extraído	Contenido principal	Entidades que alimenta
Olympics Dataset by KeithGalli	bios.csv	Datos biográficos del atleta (nombre, nacimiento, medidas y afiliaciones)	atleta, club, atleta_club y pais
Olympics Dataset by KeithGalli	results.csv	Resultado por evento/atleta (posición, medalla, disciplina)	participacion, evento, deporte, edicion, equipo
Olympics Dataset by KeithGalli	population.csv	Valores de la población en base al país (NOC) y año	poblacion
Olympics Dataset by KeithGalli	noc_regions.csv	id de los paises (NOC), su nombre y región	pais
120 years of olympic history athletes and results by heesoo37	athlete_events.csv	Un renglón por atleta-evento con edad/altura/peso, equipo, año, ciudad, deporte, medalla	atleta, participacion, evento, edicion, deporte, equipo, pais
Summer Olympics Medals (1896-2024) by stefanydeoliveira	olympics_dataset.csv	Registro histórico de Verano 1896–2024, deporte/evento/medalla	participacion, evento, deporte, edicion

Fuente	Archivo extraído	Contenido principal	Entidades que alimenta
datasets olympics by datacamp	datalab_export.csv	Dataset "Olympics" de R (ciudad, año, deporte, atleta, país, género, evento, medalla)	participacion, evento, deporte, edicion, atleta

Nota sobre bios.csv y results.csv: según el propio repositorio de KeithGalli, ambos archivos provienen de olympedia.org y se relacionan entre sí por `athlete_id`. Esa llave es la que se preserva como `atleta_id` (litearlmente lo pasamos a español) en el modelo unificado (con reasignación de IDs al momento de la carga, ya que cada fuente trae su propio identificador).

Como las cuatro fuentes describen el mismo dominio con columnas distintas (`Sport` vs. `Discipline`, `Team` vs. `NOC`, `Pos` vs. `Rank`, etc.).

2. Entidades

2.1 pais

Representa un Comité Olímpico Nacional (NOC) o país participante (una sede).

Atributo	Tipo	Descripción	Llave
pais_id	varchar(3)	Código NOC	PK
nombre_pais	varchar(100)	Nombre del NOC	-
region	varchar(100)	Agrupación continental	-

2.2 poblacion

Represnta a la cantidad de personas que habitan el pais durante la edición y evento en base a un anio y un pais.

Atributo	Tipo	Descripción	Llave
pais_id	varchar(3)	identificador pais (NOC)	PK
anio	int	nombre del club/affiliations	PK

Atributo	Tipo	Descripción	Llave
poblacion	int	total de habitantes de un pais en base al anio	-

2.3 atleta

Un deportista individual, con sus datos biográficos.

Atributo	Tipo	Descripción	Llave
atleta_id	int	Identificador interno del atleta	PK
nombre_completo	varchar(255)	Nombre completo (bios.csv: Full name)	-
nombre_usado	varchar(255)	Nombre con el que se le conoce (bios.csv: Used name)	-
sexo	varchar(1)	M / F	-
fecha_nacimiento	date	fecha	-
lugar_nacimiento	varchar(255)	dirección de nacimiento	-
fecha_fallecimiento	date	Nulo si aplica	-
lugar_fallecimiento	varchar(255)	Nulo si aplica	-
estatura_cm	int	De Measurements en bios.csv	-
peso_kg	int	De Measurements en bios.csv	-
pais_id	varchar(3)	Nacionalidad principal declarada	FK

2.4 edicion

Una edición específica de los Juegos Olímpicos.

Atributo	Tipo	Descripción	Llave
edicion_id	int	identificador	PK
nombre_edicion	varchar(100)	Ej. 1924 Summer Olympics	-
anio	int	Año de celebración	-

Atributo	Tipo	Descripción	Llave
temporada	varchar(10)	Verano / Invierno	-
ciudad	varchar(100)	Ciudad sede	-
pais_sede_id	varchar(3)	País sede de esa edición	FK

2.5 deporte

Catálogo de deportes/disciplinas (unifica `Sport` y `Discipline` de las fuentes).

Atributo	Tipo	Descripción	Llave
deporte_id	int	identificador	PK
nombre_deporte	varchar(100)	Nombre normalizado del deporte	-

2.6 evento

Una prueba específica dentro de un deporte, en una edición determinada, por ejemplo: "Singles, Men" de Tenis en 1924.

Atributo	Tipo	Descripción	Llave
evento_id	int	Identificador del evento	PK
edicion_id	int	Edición a la que pertenece	FK
deporte_id	int	Deporte al que pertenece	FK
nombre_evento	varchar(255)	Nombre de la prueba/evento	-

2.7 equipo

Agrupa a los atletas que compitieron como escuadra/selección/dupla en un evento puntual (relevos, dobles, deportes de equipo). Permite modelar resultados grupales sin duplicar el resultado por cada atleta.

Atributo	Tipo	Descripción	Llave
equipo_id	int	identificador del equipo	PK

Atributo	Tipo	Descripción	Llave
evento_id	int	Evento en el que compitió ese equipo	FK
pais_id	varchar(3)	País/selección que representa (nulo si es equipo mixto/club)	FK
nombre_equipo	varchar(150)	Nombre del equipo tal como aparece en la fuente	-

2.8 club

Club o institución a la que estuvo afiliado un atleta (bios.csv: `Affiliations`).

Atributo	Tipo	Descripción	Llave
club_id	int	identificador del club/affliations	PK
nombre_club	varchar(255)	nombre del club/affiliations	-
pais_id	varchar(3)	País del club, si se conoce	FK

2.9 atleta_club

Tabla puente ya que un atleta puede haber pertenecido a varios clubes a lo largo de su carrera, y un club tiene varios atletas afiliados.

Atributo	Tipo	Descripción	Llave
atleta_id	int	identificador de atleta	Compuesta
club_id	int	identificador del club/affiliations	Compuesta

2.10 participacion

Cada renglón es la participación de un atleta en un evento (equivalente a un renglón de `results.csv` o `athlete_events.csv`).

Atributo	Tipo	Descripción	Llave
participacion_id	int	identificador	PK
atleta_id	int	Atleta que participó	FK

Atributo	Tipo	Descripción	Llave
evento_id	int	Evento en el que participó	FK
equipo_id	int	Equipo/escuadra, si aplica	FK o nulo
pais_representado_id	varchar(3)	NOC bajo el cual compitió en esa participación	FK
nombre_en_competencia	varchar(255)	Nombre bajo el que compitió (results.csv: As)	-
posicion	varchar(20)	Posición final, admite valores no numéricos (=17, DNS, DNF)	-
medalla	varchar(10)	Oro / Plata / Bronce / nulo si no hubo medalla	-

Nota: en `pais_representado_id` puede diferir de `atleta.pais_id` si cambió de nacionalidad deportiva, por eso se hace énfasis sobre a participación.

3. Relaciones y cardinalidad

Entidad A	Entidad B	Cardinalidad	Descripción
pais	atleta	1:N	Un país es la nacionalidad de muchos atletas, un atleta tiene un país de nacionalidad principal
pais	edicion	1:N	Un país puede haber sido sede de varias ediciones, una edición tiene un único país sede
pais	poblacion	1:N	la población de un país depende del país y del año en específico.
pais	equipo	1:N	Un país puede tener muchos equipos (uno por evento en el que compitió), un equipo representa a un solo país
pais	club	1:N	Un país puede tener muchos clubes registrados, un club pertenece a un país

Entidad A	Entidad B	Cardinalidad	Descripción
pais	participacion	1:N	Un país es representado en muchas participaciones, cada participación se hace bajo un solo país
edicion	evento	1:N	Una edición agrupa muchos eventos, un evento pertenece a una sola edición
deporte	evento	1:N	Un deporte agrupa muchos eventos, un evento pertenece a un solo deporte
evento	equipo	1:N	Un evento puede tener varios equipos inscritos, un equipo compite en un solo evento
evento	participacion	1:N	Un evento tiene muchas participaciones (una por atleta), una participación ocurre en un solo evento
equipo	participacion	1:N	Un equipo agrupa las participaciones de varios atletas, una participación pertenece a lo sumo a un equipo (individual nulo)
atleta	participacion	1:N	Un atleta tiene muchas participaciones a lo largo de su carrera, una participación corresponde a un solo atleta
atleta	club	N:M	Un atleta puede pertenecer a varios clubes, un club tiene varios atletas afiliados

4. Diagrama ER

El siguiente es el código utilizado para modelar la base de datos en dbdiagram

```
Table pais {
  pais_id varchar(3) [pk]
  nombre_pais varchar(100) [not null]
  region varchar(100)
}

Table poblacion {
  pais_id varchar(3) [ref: > pais.pais_id]
  anio int
  poblacion bigint

  indexes {
    (pais_id, anio) [pk]
  }
}

Table atleta {
  atleta_id int [pk, increment]
  nombre_completo varchar(255) [not null]
  nombre_usado varchar(255)
  sexo varchar(1)
  fecha_nacimiento date
  lugar_nacimiento varchar(255)
  fecha_fallecimiento date
  lugar_fallecimiento varchar(255)
  estatura_cm int
  peso_kg int
  pais_id varchar(3) [ref: > pais.pais_id]
}

Table edicion {
  edicion_id int [pk, increment]
  nombre_edicion varchar(100) [not null]
  anio int [not null]
  temporada varchar(10) [not null]
  ciudad varchar(100)
  pais_sede_id varchar(3) [ref: > pais.pais_id]
}

Table deporte {
  deporte_id int [pk, increment]
  nombre_deporte varchar(100) [not null, unique]
}
```

```
Table evento {
  evento_id int [pk, increment]
  edicion_id int [not null, ref: > edicion.edicion_id]
  deporte_id int [not null, ref: > deporte.deporte_id]
  nombre_evento varchar(255) [not null]
}

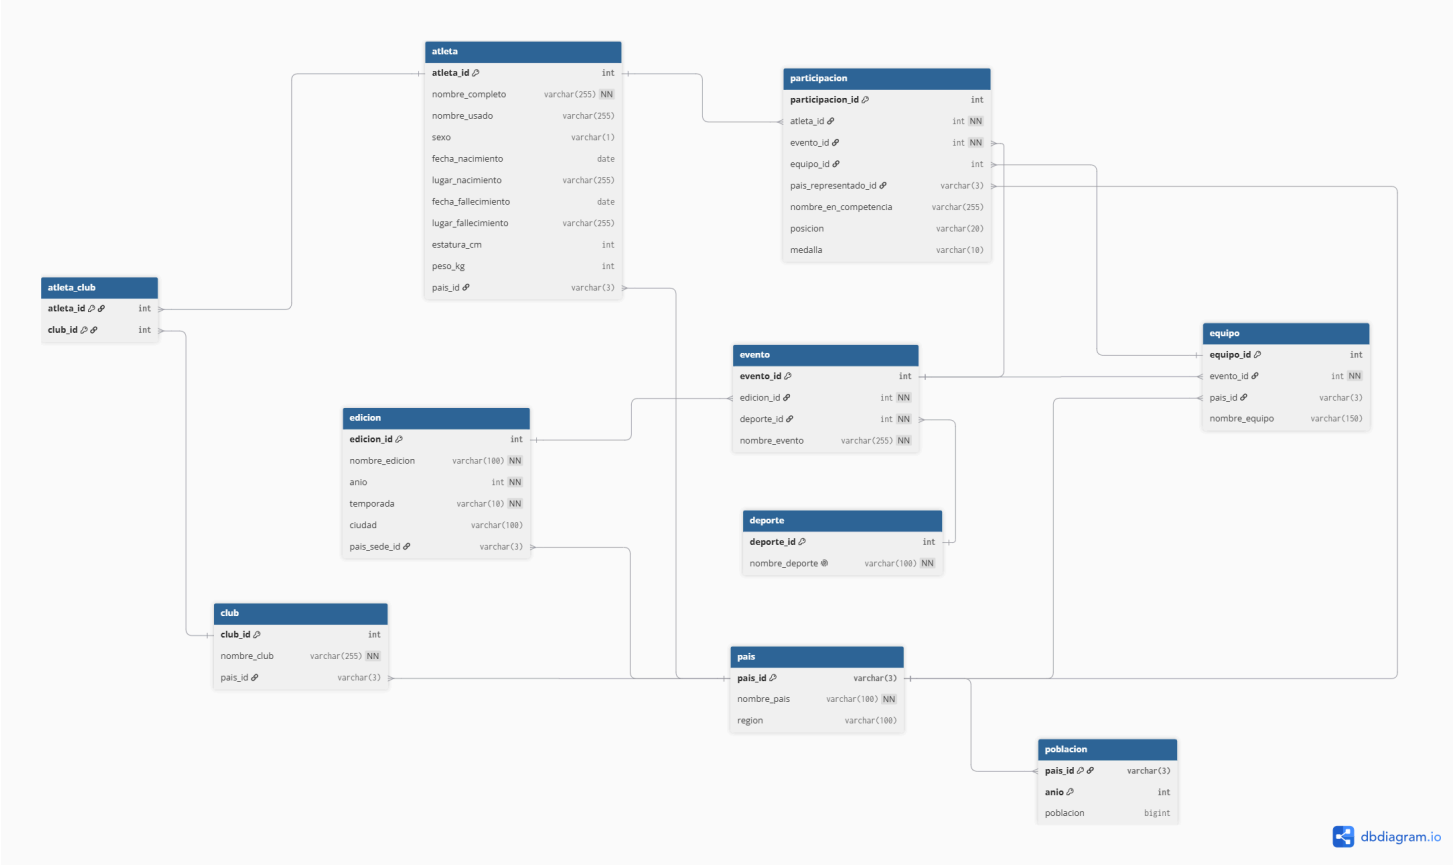
Table equipo {
  equipo_id int [pk, increment]
  evento_id int [not null, ref: > evento.evento_id]
  pais_id varchar(3) [ref: > pais.pais_id]
  nombre_equipo varchar(150)
}

Table club {
  club_id int [pk, increment]
  nombre_club varchar(255) [not null]
  pais_id varchar(3) [ref: > pais.pais_id]
}

Table atleta_club {
  atleta_id int [ref: > atleta.atleta_id]
  club_id int [ref: > club.club_id]

  indexes {
    (atleta_id, club_id) [pk]
  }
}

Table participacion {
  participacion_id int [pk, increment]
  atleta_id int [not null, ref: > atleta.atleta_id]
  evento_id int [not null, ref: > evento.evento_id]
  equipo_id int [ref: > equipo.equipo_id]
  pais_representado_id varchar(3) [ref: > pais.pais_id]
  nombre_en_competencia varchar(255)
  posicion varchar(20)
  medalla varchar(10)
}
```



Nota: El sitio web permite exportar hacia: PostgresSQL, MySQL, Oracle o SQL server. Por fines prácticos fue exportado a PostgresSQL.

5. Decisiones de diseño y supuestos

- **`deporte` unifica `Sport` y `Discipline`.** Las fuentes usan ambos términos de forma inconsistente; se normalizan a un único catálogo durante el ETL.
- **`equipo` es opcional.** En eventos individuales, `participacion.equipo_id` queda nulo; solo se usa en relevos, dobles y deportes de equipo, evitando así una tabla `equipo` vacía o forzada para la mayoría de los registros.
- **`pais_representado_id` vs. `atleta.pais_id`.** Se separan porque un atleta puede competir por más de un país a lo largo de su carrera (cambios de nacionalidad deportiva); `atleta.pais_id` guarda la nacionalidad de referencia y `participacion.pais_representado_id` la usada en cada participación puntual, esto también resuelve el requerimiento e) de listar participaciones por país.
- **`posicion` como texto, no numérico.** Los datasets incluyen valores no numéricos como `DNS`, `DNF`, `=17`, por lo que se modela como `varchar`.
- **`club` / `atleta_club` es una extensión opcional** alimentada solo por `bios.csv` (columna `Affiliations`, que trae varias afiliaciones separadas

por `/`).

6. Carga de datos (ETL)

El script `etl/build_load.py` lee las 7 fuentes de la sección 1, resuelve el mapeo de columnas repetidas entre fuentes (`Sport` / `Discipline` / `sport`, `Team` / `NOC` / `noc`, `Pos`, etc.) y genera un CSV por tabla en `etl-csvs/` (archivos auxiliares versionados en el repositorio; se regeneran con el script si hace falta). `etl/load.sql` carga esos CSVs a PostgreSQL respetando el orden de llaves foráneas y sincroniza las secuencias de los `IDENTITY` para que los próximos `INSERT` (p. ej. desde los stored procedures) no choquen con los ids ya cargados.

Para levantar todo en Docker:

```
python3 etl/build_load.py   # genera etl-csvs/*.csv
bash etl/run_load.sh        # levanta docker-compose (postgres:16), aplica src/schema.sql y carg
```

6.1 Regla de deduplicación de atletas

Un atleta se identifica por su nombre. Al procesar un nuevo renglón:

- Si ya existe un atleta con ese nombre y **ningún** atributo comparable (sexo, país) difiere del nuevo registro, es el mismo atleta: se reutiliza su `atleta_id` y se completan los campos que le faltaban (fecha de nacimiento, medidas, etc.) con los datos de la fuente nueva.
- Si algún atributo comparable varía, aunque sea solo el país de origen, no es el mismo atleta: se crea un registro nuevo con el mismo nombre (homónimo legítimo).
- Los nombres se comparan sin distinguir mayúsculas/minúsculas ni acentos/diacríticos (p. ej. "Cenk İldem" y "Cenk Ildem", transliterado en una de las fuentes, resuelven al mismo `atleta_id`).

`bios.csv` y `results.csv` comparten `athlete_id` (ambos vienen de olympedia.org), así que para `results.csv` no se vuelve a resolver identidad: sus participaciones se enlazan directamente al `atleta_id` ya creado a partir de `bios.csv`.

Con esta regla, sobre las ~950 mil filas de las 7 fuentes se obtuvieron **242,021 atletas** (0 duplicados exactos por nombre+sexo+país, verificado en la base ya cargada) y **693,327 participaciones**, también deduplicadas por la llave natural (atleta, evento, país representado): si la misma participación aparece en más de una fuente, se conserva un solo renglón y se completan `posición` / `medalla` con lo que aporte cada fuente.

6.2 Supuestos adicionales de la carga

- **`equipo` se deriva después de la carga base.** La carga inicial deja `participacion.equipo_id` nulo; posteriormente `etl/derivar_equipos.sql` detecta eventos colectivos y enlaza las participaciones cuando existen al menos dos atletas del mismo país en el evento. La heurística y sus validaciones se explican en la sección 8.
- **Sede de la edición (`edicion.pais_sede_id`)** se resuelve con un diccionario ciudad-país de las sedes olímpicas conocidas; ediciones que solo llegan por `results.csv` (sin ciudad) usan un diccionario equivalente por nombre de edición. Juegos Olímpicos de la Juventud, Intercalados, etc. quedan sin sede si no están en ese diccionario.
- **`poblacion`** mapea el código ISO-3166 de `populations.csv` al código NOC/IOC del catálogo de `pais` (difieren en ~20 países, por ejemplo `DEU` - `GER` , `CHE` - `SUI`); los códigos que son agregados regionales del Banco Mundial (`AFE` , `ARB` , `OED` , etc.) no tienen país real y se descartan (127 de los ~267 códigos de la fuente).
- **Nacionalidad en `bios.csv` .** La columna `NOC` de esa fuente trae texto libre (a veces varios países concatenados) y no un código; se usa en su lugar el código entre paréntesis al final de `Born` (p. ej. "... (FRA)").

7. Stored procedures

El archivo `src/stored_procedures.sql` crea dos procedimientos. Cada uno deja el resultado detallado en una tabla temporal para consultarlo desde `psql` y muestra por `NOTICE` cuántas filas produjo.

7.1. `sp_info_atleta`

Recibe el nombre completo o una parte del nombre del atleta y deja su información biográfica, edición, deporte, evento, país representado, posición, medalla y equipo en `resultado_sp_info_atleta`.

Filtros opcionales:

- `p_deporte`: nombre o parte del deporte.
- `p_pais`: código NOC o nombre del país representado.
- `p_anio`: año de la edición.

7.2. `sp_info_pais`

Recibe un código NOC o una parte del nombre del país y deja en `resultado_sp_info_pais` la población más reciente, sus ediciones como sede y sus participaciones con atleta, deporte, evento, posición, medalla y equipo.

Filtros opcionales:

- `p_anio`: año de la edición.
- `p_deporte`: nombre o parte del deporte.
- `p_medalla`: medalla exacta, por ejemplo `Oro`.

Las consultas completas para probar ambos procedimientos están en `ejemplos.md`.

8. Derivación y verificación de equipos

El archivo `etl/derivar_equipos.sql` se ejecuta automáticamente desde `etl/run_load.sh`, después de `etl/load.sql` y antes de `src/stored_procedures.sql`.

La detección considera deportes inherentemente colectivos (fútbol, baloncesto, voleibol, hockey, rugby, béisbol, entre otros) y eventos cuyo nombre contiene términos como `relay`, `relevo`, `double`, `pair`, `team` o `4x`. Dentro de esos eventos se agrupan las participaciones por

`(evento_id, pais_representado_id)`. Solo se crea un equipo cuando el grupo tiene al menos dos atletas.

El script es idempotente: desvincula las participaciones existentes, elimina los equipos derivados con `DELETE` para conservar la FK sin borrar participaciones, vuelve a insertar los equipos y enlaza nuevamente sus participaciones. Las consultas de `ejemplos.md` verifican la cantidad de equipos y que no existan referencias huérfanas.

9. Evidencia de ejecución

Capturas con fecha de una corrida completa del pipeline (esquema, carga, derivación de equipos y los dos stored procedures) en `docs/evidencia.md`.